

Линейна регресия

Тема: Aerobic fitness


Изготвил: Кирил Романски

Цел: Да се разработи уравнение за предсказване на финеса (измерван чрез способността за приемане на кислород) на база упражнения, вместо ползването на скъпи и трудно изпълними измервания на кислородната консумация. Тези измервания са извършени върху мъже, участващи в курс по физическа подготовка.

Обработка и предварителен анализ на данни: Файлът с данни съдържа 7 променливи

Възраст-в години; Тегло-в килограми; Кислород-прием на кислород милилитри на килограм телесно тегло за минута; Време_на_бягане-време за завършване на 1.5 мили (в минути); Пулс_в_покой; Пулс_бягане; Максимален_Пулс.

Графики на разпределения и плътности: Първо ще разгледаме разпределението на целевата променлива - Кислород, тъй като нейното разпределение е най-важно и е свързано с това какъв модел ще ползваме и хипотезите, който ще тестваме.



Разпределението изглежда нормално ще направим и Шапиро тест за всеки случай.

```
> shapiro.test(data$Oxygen)


Shapiro-Wilk normality test

data: data$Oxygen
W = 0.95366, p-value = 0.1968
```

п-стойността е голяма дори не близко до 0.05, тоест можем да приемем, че нашия отклик Килород е нормално разпределен.


Останалите промеливи не е задължително да са нормално разпределени, но все пак е важно да видим тяхното разпределение и техните интервали, тъй като голяма разлика в интервала на данните може да изкриви нашия модел, и дали има голямо изместване.

Възраст:




Разпределението изглежда нормално и няма аутляяри или различна скала на измерванията

Тегло:




Приблизително нормално разпределение.

Време_на_бягане:





Пулс_в_покой:




Тук можем да видим че разпределението не прилича на нормално, но това не е проблем, това е предикторна променлива.

Пулс_бягане:



Максимален пулс:



Тук хистограмата изглежда така защото сме дали повече стълбове. От плътността се вижда, че разпределението е приблизително нормално.

```
> summary(Adult)
   Age          Weight         Oxygen        RunTime      RestPulse      RunPulse      MaxPulse
Min. :38.00    Min. :59.08    Min. :37.39    Min. : 8.17    Min. :40.00    Min. :146.0    Min. :155.0
1st Qu.:44.00  1st Qu.:73.20  1st Qu.:44.96  1st Qu.: 9.78  1st Qu.:48.00  1st Qu.:163.0    1st Qu.:168.0
Median :48.00  Median :77.45  Median :46.77  Median :10.47  Median :52.00  Median :170.0    Median :172.0
Mean   :47.68  Mean   :77.44  Mean   :47.38  Mean   :10.59  Mean   :53.45  Mean   :169.6    Mean   :173.8
3rd Qu.:51.00  3rd Qu.:82.33  3rd Qu.:50.13  3rd Qu.:11.27  3rd Qu.:58.50  3rd Qu.:176.0    3rd Qu.:180.0
Max.   :57.00  Max.   :91.63  Max.   :60.05  Max.   :14.03  Max.   :70.00  Max.   :186.0    Max.   :192.0
```

Стандартни отклонения на променливите:

Age	Weight	Oxygen	RunTime	RestPulse	RunPulse	MaxPulse
5.211443	8.328568	5.327231	1.387414	7.619443	10.251986	9.164095

Корелационна матрица:

```
> cor(data)
      Age      Weight    Oxygen   RunTime  RestPulse  RunPulse  MaxPulse
Age  1.0000000 -0.2335390 -0.3045924  0.1887453 -0.16409995 -0.3378703 -0.4329159
Weight -0.2335390  1.0000000 -0.1627528  0.1435076  0.04397417  0.1815163  0.2493812
Oxygen -0.3045924 -0.1627528  1.0000000 -0.8621949 -0.39935611 -0.3979742 -0.2367402
RunTime  0.1887453  0.14350758 -0.8621949  1.0000000  0.45038260  0.3136478  0.2261030
RestPulse -0.1640999  0.04397417 -0.3993561  0.4503826  1.00000000  0.3524606  0.3051240
RunPulse -0.3378703  0.18151633 -0.3979742  0.3136478  0.35246060  1.0000000  0.9297538
MaxPulse -0.4329159  0.24938123 -0.2367402  0.2261030  0.30512400  0.9297538  1.0000000

```

Силна корелация между Максималния пулс и Пулса по време на бягане, което е съвсем логично, когато правим модела ще проверим кое ни носи повече информация и ще премахнем другото, за да нямаме мултиколинеарност. Друга силна корелация можем да видим между кислорода и Времето_за_бягане тоест можем да очакваме, че това ще бъде важна променлива за нашия модел. Направих и модел само с тази променлива като начална отправна точка на нашия експеримент.


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	82.4218	3.8553	21.379	< 2e-16 ***
RunTime	-3.3106	0.3612	-9.166	4.59e-10 ***


Signif. codes: 0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1				
Residual standard error: 2.745 on 29 degrees of freedom				
Multiple R-squared: 0.7434, Adjusted R-squared: 0.7345				
F-statistic: 84.01 on 1 and 29 DF, p-value: 4.585e-10				

> |

И както виждаме този модел се представя доста добре дори само с 1 предиктор.



Скатер плот на променливите с Кислород. Идеята на тази графика е да видим дали някъде имаме нелинейна зависимост между отклика и предикторите и да видим дали са нужди някакви трансформации.



Не мога да видя никаква зависимост нелинейна между Кислорода и останалите променливи, така че можем да започнем със изграждане на модела.

Първи модел: За начало ще използваме всички предиктори и ще направим пълен модел

```

> m=lm(Oxygen~., data=data)
> summary(m)

Call:
lm(formula = Oxygen ~ ., data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-5.4026 -0.8991  0.0706  1.0496  5.3847 


Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 102.93448   12.40326   8.299 1.64e-08 ***
Age          -0.22697    0.09984  -2.273  0.03224 *  
Weight        -0.07418    0.05459  -1.359  0.18687    
RunTime       -2.62865    0.38456  -6.835 4.54e-07 ***
RestPulse     -0.02153    0.06605  -0.326  0.74725    
RunPulse      -0.36963    0.11985  -3.084  0.00508 ** 
MaxPulse      0.30322    0.13650   2.221  0.03601 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.317 on 24 degrees of freedom
Multiple R-squared:  0.8487,    Adjusted R-squared:  0.8108 
F-statistic: 22.43 on 6 and 24 DF,  p-value: 9.715e-09


```

> |

Модела се представя добре и има висок коефициент на детерминация-0.81, но не твърде висок. Има предиктори, които могат да бъдат премахнати, но за първи се представя добре. Имайки предвид, че нашия експеримент е само с 31 наблюдения целта ни ще бъде около 3 предиктора. Нека сега проверим остатъците и дали модела е правилен.



Normal Q-Q Plot



Остатъците изглеждат нормално разпределени. Не се вижда никаква зависимост в от графиката.

VIF на предикторите: Ще пресметнем мултиколинеарност използвайки variance inflation factor, който се смята по формулата $Vif_{xj} = 1/(1-R_j)$ където R_j е коеф. на детерминация на линеен модел фитнат върху j -тия предиктор. Идеята е да тестваме каква информация ни носи съответният предиктор спрямо линейна комбинация на останалите, което простата корелация не може да оцени. Имайки предвид, че корелацията между MaxPulse и RunPulse

е голяма очакваме големи стойности на vif за тези две променливи всичко над 5 ще считаме за мултиколинеарност

```
> vif(m)
    Age      Weight     RunTime RestPulse   RunPulse MaxPulse
1.512836  1.155329  1.590868  1.415589  8.437274  8.743848
> |
```

И както предполагахме RunPulse и MaxPulse имат >5 стойност на vif. Ще поправим този проблем като махнем една от променливите, но първо ще направим стъпкова регресия, за да видим оптималния модел.

Стъпкова регресия: С функцията `step(model, direction="backward")` ще направим премахване на слаби предиктори. Посоката е backward понеже вече имаме целия модел и ще махаме.

```
> stepwise_reg=step(m, direction = "backward")
Start: AIC=58.16
Oxygen ~ Age + Weight + RunTime + RestPulse + RunPulse + MaxPulse

          Df Sum of Sq    RSS    AIC
- RestPulse  1    0.571 129.41 56.299
<none>                 128.84 58.162
- Weight     1    9.911 138.75 58.459
- MaxPulse   1   26.491 155.33 61.958
- Age        1   27.746 156.58 62.208
- RunPulse   1   51.058 179.90 66.510
- RunTime    1  250.822 379.66 89.664

Step: AIC=56.3
Oxygen ~ Age + Weight + RunTime + RunPulse + MaxPulse

          Df Sum of Sq    RSS    AIC
<none>                 129.41 56.299
- Weight     1    9.52 138.93 56.499
- MaxPulse   1   26.83 156.23 60.139
- Age        1   27.37 156.78 60.247
- RunPulse   1   52.60 182.00 64.871
- RunTime    1  320.36 449.77 92.917
> |
```

Виждаме, че `step` функцията махна само 1 предиктор, но това не означава, че модела е добър. AIC функцията представлява: $AIC=2k-2\ln(L)$ където k са параметрите, а L максимизиран likelihood. Тоест теоритично тази функция оценява, колко добре данните фитват модела

като има наказание за повече предиктори. Това обаче не контролира дали предикторите са мултиколинеарни или не. За това сами ще maxаме предиктори и, ако не свалим много R квадрата ще даваме приоритет на модел с по-малко предиктори. Maxаме предитора Тегло(Weight) и предиктора RestPulse, тъй като имат големи p-стойности.

```
> m_reduced=lm(Oxygen~Age+RunTime+RunPulse+MaxPulse,data=data)
> summary(m_reduced)

Call:
lm(formula = Oxygen ~ Age + RunTime + RunPulse + MaxPulse, data = data)


Residuals:
    Min      1Q  Median      3Q     Max 
-4.9685 -1.1654 -0.0636  1.2004  4.7726 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 98.14789   11.78569   8.328 8.26e-09 ***
Age         -0.19773    0.09564  -2.068  0.04877 *  
RunTime     -2.76758    0.34054  -8.127 1.31e-08 ***
RunPulse    -0.34811    0.11750  -2.963  0.00644 ** 
MaxPulse    0.27051    0.13362   2.024  0.05330 .  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.312 on 26 degrees of freedom
Multiple R-squared:  0.8368,    Adjusted R-squared:  0.8117
```

Добре от модела се вижда, че r-квадрат почти не падна, но за сметка на това модела е по-прост и остатъците изглеждат по-добре като ги начертаем срещу теоритичните квантили.

Normal Q-Q Plot



Остана само да пробваме да махнем мултиколинеарността от модела, което ще направим като премахнем предиктора MaxPulse. Защо него? Ами той има по висока p-стойност и реално е незначим за ниво на доверие 0.95.

Модел без MaxPulse:

Oxygen~Age+RunTime+RunPulse

```
> summary(m_final)

Call:
lm(formula = Oxygen ~ Age + RunTime + RunPulse, data = data)


Residuals:
    Min      1Q  Median      3Q     Max 
-4.8752 -1.2493  0.2606  1.0324  4.8994 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 111.71806   10.23509 10.915 2.10e-11 ***
Age         -0.25640    0.09623 -2.664   0.0129 *  
RunTime     -2.82538    0.35828 -7.886 1.77e-08 ***
RunPulse    -0.13091    0.05059 -2.588   0.0154 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1


Residual standard error: 2.441 on 27 degrees of freedom
Multiple R-squared:  0.8111,    Adjusted R-squared:  0.7901 
F-statistic: 38.64 on 3 and 27 DF,  p-value: 6.557e-10
```

Малко се намалява коеф. на детерминация, но това не стига, за да използваме по-сложен модел.

Normal Q-Q Plot




Тук обаче виждаме проблем, остатъците се влошиха, което значи, че може някое от преположенията, които имаме да са нарушени ще плотнем и остатъците срещу нулата да видим дали там ще намерим някаква зависимост.



Изглеждат добре, не се вижда зависимост, нека проверим дали някое наблюдение не дърпа целия модел надолу. Ще сметнем дали някой от остатъците е на повече от 2 стандартни отклонения. Първо ги стандартизираме с `which` функцията ще намерим индекса на даденото наблюдение.

```
> which(abs(rstandard(m_final)) > 2*sd(rstandard(m_final)))
 8  9  21
```

Нека видим тези аутляяри срещу фитнати стойности



Нека пробваме модела без тези наблюдения, да видим как ще се представи.

```

> m_final_cleaned=lm(Oxygen~Age+RunTime+RunPulse,data=data_cleaned)
> summary(m_final_cleaned)

Call:
lm(formula = Oxygen ~ Age + RunTime + RunPulse, data = data_cleaned)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.0419 -0.8947  0.1947  1.0287  4.3669 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 107.41024   8.25276 13.015 2.29e-12 ***
Age          -0.21779   0.08100 -2.689  0.01283 *  
RunTime       -2.60652   0.28366 -9.189 2.50e-09 ***
RunPulse      -0.13111   0.03933 -3.333  0.00278 ** 
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.894 on 24 degrees of freedom
Multiple R-squared:  0.862,    Adjusted R-squared:  0.8448 
F-statistic: 49.98 on 3 and 24 DF,  p-value: 1.791e-10

```

Финалния модел без аутляари. Коеф. на детерминация скочи до 0.86, което е много добре. Редуцирания модел в който има Максималния пулс също се представя подобно, малко по-добре и остатъците изглеждат по-добре.

Финални проверки: Тъй като моделите се представят доста добре ни остана да проверим едно нещо: Кой е по-добър? Модела с MaxPulse има по ниска AIC стойност и по-добри показатели като коеф. На детерминация и остатъците се съпоставят по-добре към нормално разпределение, но има един проблем-мултиколинеарност между предикторите. Финалния модел без MaxPulse няма този проблем, но се преставя малко по-зле. Тъй като нямаме много данни (само 31) единствения вариант, който можем да използваме за някакъв вид валидация на моделите е крос валидация LOOCV. Ще тренираме модела на 30 точки и ще предвиждаме 1-та останала. Така ще имаме 31 остатъка и ще сравним моделите като този с по-малка сума на грешките ще бъде финалния ни модел.


```
> cat("LOOCV предикшън грешка на пълния модел.", error_full)
LOOCV предикшън грешка на пълния модел: 6.083837
> cat("LOOCV предикшън грепка на редуцирания модел:", error_reduced)
LOOCV предикшън грепка на редуцирания модел: 6.616924
> |
```


Излиза, че все пак мултиколинеарността няма толкова голямо значение и модела включващ MaxPulse е по-добър.

Заключение: Финалния модел е Oxygen~Age+RunTime+RunPulse+MaxPulse. Този модел е удачен, защото както видяхме по-горе връзката между отклика и предикторите изглежда линейна, никъде не присъства квадратична или кубична зависимост. Използвах линейна регресия и поради причината, че е лесно изчислена и лесно може да се интерпретира резултата. Разпределението на остатъците е нормално, което е нашето най-важно допускане и то е изпълнено. R квадрата висок 0.87, което допълнително показва устойчивостта на модела и колко са сполучливи нашите предиктори. За жалост нямаме достатъчно данни, за да направим качествена диагностика. Най-доброто, за което се сетих е leave one out крос валидация, която има стойте недостатъци е добър алгоритъм за валидиране, с чиято помощ и решихме кой да е финалния модел.

```
Call:  
lm(formula = Oxygen ~ Age + RunTime + RunPulse + MaxPulse, data = data_cleaned)  
  
Residuals:  
    Min      1Q  Median      3Q     Max  
-3.7121 -1.1721  0.1139  0.9778  4.1953  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)  
(Intercept) 101.91653    9.84759 10.349 3.98e-10 ***  
Age          -0.20525    0.08186 -2.508  0.0197 *  
RunTime      -2.61593    0.28357 -9.225 3.42e-09 ***  
RunPulse     -0.24485    0.11819 -2.072  0.0497 *  
MaxPulse      0.14010    0.13729  1.020  0.3181  
---  
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1  
  
Residual standard error: 1.892 on 23 degrees of freedom  
Multiple R-squared:  0.868,    Adjusted R-squared:  0.8451  
F-statistic: 37.81 on 4 and 23 DF,  p-value: 8.452e-10
```

Normal Q-Q Plot





Код:

```
142 #####
143 #####
144 ##### SECOND PROJECT IN CASE DATASET 8 AIR POLUTION !!!
145
146 list.files()
147 install.packages("sas7bdat")
148 library("sas7bdat")
149 data=read.sas7bdat("C:\\\\Users\\\\kiril\\\\Downloads\\\\fitness.sas7bdat")
150 summary(data)
151 data
152 par(mfrow = c(1, 2)) # 1 row, 2 columns (side by side)
153
154 hist(data$Oxygen)
155 plot(density(data$Oxygen))
156 hist(data$Age)
157 plot(density(data$Age))
158 hist(data$Weight)
159 plot(density(data$Weight))
160 hist(data$RunTime)
161 plot(density(data$RunTime))
162 hist(data$RestPulse)
163 plot(density(data$RestPulse))
164 hist(data$RunPulse)
165 plot(density(data$RunPulse))
166 hist(data$MaxPulse)
167 plot(density(data$MaxPulse))
168 install.packages("GGally")
169 library(GGally)
170 ggpairs(data)
171 plot(data$RunTime, data$Oxygen)
172 abline(lm(Oxygen ~ RunTime, data = data))
173 plot(data$Oxygen,data$Weight)
174 first_model=lm(Oxygen~RunTime,data=data)
175 summary(first_model)
176 plot(residuals(first_model))
177 abline(h=0,col="red",lty=2)
178
179 sapply(data, sd)
180 summarise(data)
181
```

```
180 summary(data)
181 shapiro.test(data$MaxPulse)
182 cor(data)
183 m=lm(Oxygen~., data=data)
184 summary(m)
185 plot(residuals(m))
186 abline(h=0,col="red",lty=2)
187 qqnorm(residuals(m))
188
189 library(car)
190 vif(m)
191 stepwise_reg=step(m, direction = "backward")
192 summary(stepwise_reg)
193 m_reduced=lm(Oxygen~Age+RunTime+RunPulse+MaxPulse,data=data)
194 summary(m_reduced)
195 qqnorm(residuals(m_reduced))
196
197
198 m_final=lm(Oxygen~Age+RunTime+RunPulse,data=data)
199 summary(m_final)
200 plot(m_final)
201 plot(rstandard(m_final))
202 qqnorm(residuals(m_final))
203 abline(h=0, col="red",lty=2)
204 ?which
205 max(abs(residuals(m_final)))
206 sd(residuals(m_final))
207 which(abs(rstandard(m_final)) > 2*sd(rstandard(m_final)))
208 ###Имаме 3 аутляри 8,9,21 нека проверим
209 shapiro.test(residuals(m_final))
210 ###Остатьците са нормално разпределени
211 hist(residuals(m_final))
212 anova(stepwise_reg,m_final)### Резултатът е 0.06 като p-стойност което е на границата, но
213 ##не можем да кажем, че по-комплексният модел е по-добър
214 length(data$Oxygen)
215 data_cleaned=data[-c(8,9,21),]
216 m_reduced_cleaned=lm(Oxygen~Age+RunTime+RunPulse+MaxPulse,data=data_cleaned)
217 summary(m_reduced_cleaned)
218 qqnorm(residuals(m_reduced_cleaned))
219
```

```
214 length(data$oxygen)
215 data_cleaned=data[-c(8,9,21),]
216 m_reduced_cleaned=lm(Oxygen~Age+RunTime+RunPulse+MaxPulse, data=data_cleaned)
217 summary(m_reduced_cleaned)
218 qqnorm(residuals(m_reduced_cleaned))
219 m_final_cleaned=lm(Oxygen~Age+RunTime+RunPulse, data=data_cleaned)
220 summary(m_final_cleaned)
221 plot(m_final_cleaned)
222 plot(rstandard(m_final_cleaned))
223 qqnorm(residuals(m_final_cleaned))
224 abline(h=0, col="red", lty=2)
225 length(data_cleaned$Weight)
226
227 vif(m_final)
228 if (!require(boot)) install.packages("boot")
229 data
230 library(boot)
231
232 loocv_error <- function(data, formula) {
233   glm_fit <- glm(formula, data = data)
234   cv_result <- cv.glm(data, glm_fit, K = nrow(data))
235   return(cv_result$delta[1]) # чиста крос валидация за пресмятане на грешката
236 }
237
238 formula_full <- Oxygen ~ Age + RunTime + RunPulse + MaxPulse
239 formula_reduced <- Oxygen ~ Age + RunTime+ RunPulse
240
241 error_full <- loocv_error(data, formula_full)
242 error_reduced <- loocv_error(data, formula_reduced)
243
244
245 ## тук ползвам cat вместо принт просто, за да излезе и надписа concatenate and print
246 cat("LOOCV предикшън грешка на пълния модел:", error_full)
247 cat("LOOCV предикшън грешка на редуцирания модел:", error_reduced)
248
249 plot(m_reduced_cleaned)
250 plot(residuals(m_reduced_cleaned))
251 abline(h=0, col="green", lty=2 )
```